

Официальный отчёт по результатам тестирования OCR-движков с помощью метрик

Дата: 15 марта 2026

Автор: Ксения

1. Используемые движки

- Paddle + Pix2Tex
- Tesseract + Pix2Tex
- EasyOCR + Pix2Tex
- RapidOCR + Pix2Tex
- Doctr + Pix2Tex


Примечание: в отчёте каждая связка представлена в виде «OCR-движок + Pix2Tex» (распознавание текста + извлечение формул).

2. Краткое резюме (Executive summary)

- По большинству числовых метрик (CER, WER, WordF1, LCS_norm) лидируют **Tesseract+Pix2Tex** и **Paddle+Pix2Tex**.
- **Tesseract+Pix2Tex** демонстрирует небольшое преимущество по LCS_norm и по распознаванию ключевых терминов.
- Несмотря на это, **Paddle+Pix2Tex** оценивается как предпочтительная связка с практической точки зрения ввиду более стабильной и удобной работы с формулами.
- Остальные связки (особенно RapidOCR+Pix2Tex и Doctr+Pix2Tex) показывают существенно худшие результаты по распознаванию обычного текста (очень высокий CER/WER, WordF1 = 0).

3. Таблица метрик (по одному фото: photo1)

Engine (связка)	CER	WER	WordPrecision	WordRecall	WordF1	LCS_len	LCS_norm	FormulaAcc	KeyTermsAcc
Paddle+Pix2Tex	0.172646	1.56	0.98	1.0	0.989899	430	0.964126	1.0	0.857143
Tesseract+Pix2Tex	0.188341	1.66	0.98	1.0	0.989899	444	0.995516	1.0	0.857143
EasyOCR+Pix2Tex	0.298206	2.68	0.62	1.0	0.765432	144	0.322870	1.0	0.714286
RapidOCR+Pix2Tex	0.885650	7.90	0.00	1.0	0.000000	7	0.015695	1.0	0.000000
Doctr+Pix2Tex	0.769058	6.88	0.00	1.0	0.000000	7	0.015695	1.0	0.000000



4. Объяснение метрик

1. **CER (Character Error Rate)** — доля ошибочно распознанных символов в тексте.

- Значение 0 → идеальное распознавание.
- Чем выше, тем больше ошибок на уровне символов.

2. **WER (Word Error Rate)** — доля ошибочно распознанных слов.

- Учитывает вставки, пропуски и замены слов.
- Чем меньше, тем лучше.

3. **WordPrecision** — точность распознавания слов.

- Доля правильно распознанных слов среди всех предсказанных.
- 1.0 = все распознанные слова правильные.

4. **WordRecall** — полнота распознавания слов.

- Доля правильно распознанных слов среди всех слов эталона.
- 1.0 = все слова эталона найдены.

5. **WordF1** — гармоническое среднее WordPrecision и WordRecall.

- Показывает общий баланс между точностью и полнотой.

6. **LCS_len (Longest Common Subsequence length)** — длина наибольшей общей подпоследовательности символов между предсказанием и эталоном.

- Позволяет оценить, насколько текст совпадает по структуре символов.

7. **LCS_norm** — нормированное значение LCS_len (от 0 до 1).

- 1 → полный матч текста.

8. **FormulaAcc** — точность распознавания формул.

- 1 → все формулы распознаны полностью правильно.

9. **KeyTermsAcc** — точность распознавания ключевых терминов (специфические слова, важные для семантики).

- 0 → все ключевые термины потеряны; 1 → все распознаны.

5. Подробный разбор по метрикам

5.1 CER / WER / WordF1

- **Paddle+Pix2Tex** и **Tesseract+Pix2Tex** находятся в лидерах по низкому CER и низкому WER, а также по высокому WordF1 (~0.99) — это указывает на корректное распознавание большинства слов и символов.
- **EasyOCR+Pix2Tex** заметно отстаёт: CER и WER выше, WordF1 существенно ниже (~0.77).
- **RapidOCR+Pix2Tex** и **Doctr+Pix2Tex** демонстрируют крайне плохие показатели качества текста (CER ≈0.77–0.89, WordF1 = 0).

5.2 LCS (длина наибольшей общей подпоследовательности)

- **Tesseract+Pix2Tex** имеет наибольшее значение LCS_len и наилучшее нормированное значение LCS_norm (0.9955).
- **Paddle+Pix2Tex** также даёт высокий LCS_norm (0.9641), что подтверждает близость результата к эталону.

5.3 KeyTermsAcc

- **Paddle+Pix2Tex** и **Tesseract+Pix2Tex** демонстрируют одинаковое значение KeyTermsAcc (0.8571)
- **EasyOCR+Pix2Tex** имеет 0.7143, а **RapidOCR** и **Doctr** — 0.0.

6. Выводы и интерпретация

1. **Лидеры по числовым метрикам:** Tesseract+Pix2Tex и Paddle+Pix2Tex. По LCS_norm небольшое преимущество у **Tesseract+Pix2Tex**, но практическое качество работы с формулами выше у **Paddle+Pix2Tex**.
2. **Формулы:** по заявленной числовой метрике формул все связки показывают идеальный результат (FormulaAcc = 1.0).
3. **Причина использования PaddleOCR в проекте:** хотя по ряду численных показателей **Tesseract+Pix2Tex** имеет небольшое преимущество, **между Paddle+Pix2Tex и Tesseract+Pix2Tex первая связка (Paddle+Pix2Tex) предпочтительнее**, поскольку в практических условиях она демонстрирует более стабильную работу с формулами и лучшую интеграцию в пайплайн.
4. **Отдельно:** RapidOCR и Doctr показали крайне низкое качество распознавания текста и не рекомендуются к использованию с кириллицей